Sistema de Detección de Sentimiento en Reseñas de Usuarios (DSR-AI)

Definición del proyecto

Universitat Politècnica de València

Grado en Inteligencia Artificial

Proyecto I. Introducción a la IA

Adrián A. Acosta Villegas

Sergio Garfella Pérez

Ainara Sanfélix Ruiz

Jairo E. Urdaneta Colmenares

1. Contexto del proyecto

Somos un grupo de estudiantes universitarios realizando un proyecto para la asignatura Proyecto I del Grado en Inteligencia Artificial. En este trabajo nos enfrentamos a una situación real planteada por la empresa Meta.

Meta desea comprender mejor la percepción que los usuarios tienen sobre productos, restaurantes y películas. Actualmente, en muchas ocasiones dicho análisis de reseñas se sigue realizando de forma manual o mediante recuentos simples de palabras, dificultando la obtención de conclusiones fiables cuando el volumen de opiniones es elevado. La organización dispone de conjuntos de datos con reseñas escritas por usuarios y desea explorar el uso de técnicas de aprendizaje automático para identificar automáticamente si una reseña expresa un sentimiento positivo o negativo. Para mejorar la presentación semántica del texto, se propone utilizar modelos de vectores de palabras y documentos, específicamente el modelo Doc2Vec, junto con un clasificador basado en K-Nearest Neighbors (k-NN), algoritmo de vecinos cercanos.

2. Objetivo del proyecto

Desarrollar un modelo en Python capaz de clasificar las reseñas de los usuarios como positivas o negativas. El texto se representará en la aplicación utilizando Doc2Vec, y se utilizará un algoritmo de k-NN como método de clasificación. Los resultados deben ser entregados de forma comprensible y sencilla para usuarios no expertos en técnicas de inteligencia artificial (gente de marketing digital, publicidad, directivos), mediante una interfaz sencilla y amigable. El sistema pretende servir como herramienta de apoyo para el análisis de opiniones y la toma de decisiones basada en datos.

3. Interesados del proyecto (stakeholders)

Interesados	Rol en la institución	¿Que necesita del sistema?	¿Que valor obtiene?
Comprador/Usuario final	Usuario consumidor	Un análisis de un sentimiento que genera en usuarios sobre un servicio o producto	Una mejor visión de la opinión general, lo que le permite mejores decisiones de compra.
Vendedor/ Propietario	Usuario provedor	Un análisis de las tendencias que producen emociones favorables y conocer el sentimiento generado por las ventas o servicios de su negocio/producto.	Información de ayuda en la decisión de nuevos productos a incorporar (nuevas oportunidades). También evaluar el desempeño de sus productos.
Creadores de contenido	Usuario Creador	Un análisis de las emociones que produce su contenido.	Conocer qué tipo de contenido obtienen mejor recepción para futuras mejoras.
Equipo de Meta	Marketing/ Publicidad	Conocer los intereses de los usuarios según el contenido que consumen y las emociones que produce este contenido	Obtención de información para poder ofrecer una publicidad más personalizada para el usuario.
Equipo de Meta	Analistas de datos/ Desarrolladores	Conocer los intereses de los usuarios según el contenido que consumen y las emociones que produce este contenido	Utilización de la información recopilada para que, mediante un algoritmo, se recomienden al usuario vídeos con mayor probabilidad de interés.
Equipo de Meta	Directivos	Conocer los intereses de los usuarios según el contenido que consumen y las emociones que produce este contenido	Obtención de información y análisis del consumidor para la toma de decisiones de la empresa.

4. Necesidades, especificaciones y requerimientos del proyecto

El director de operaciones de Meta se ha puesto en contacto con vosotros para ofreceros la siguiente infomación:

Para ofrecer una solución al problema planteado, los datos de entrada serán textos de reseñas en formato textual, almacenados por la propia empresa. La aplicación debe clasificar automáticamente el sentimiento expresado por cada uno de llos. Para ello, se debe manejar un lenguaje natural realista, incluyendo variaciones en estilo y vocabulario, pudiendo clasificar el mayor amplio espectro de comentarios. En la aplicación final se debe poder introducir un comentario y obtener su clasificación como positivo o negativo. Dicha aplicación debe poder ejecutarse en un entorno estándar sin requerimientos complejos de infraestructura (como un ordenador de con un sistema operativo *Windows* instalado). Para ello, la dirección sugiere el uso de una pequeña interfaz web utilizando *Streamlit*.

El proyecto en su totalidad engloba la comprensión y análisis del problema y sus requisitos. Los datos proporcionados deberán ser explorados, tratados y preparados para ser usados en el modelo de clasificación. Se definirá el modelo a utilizar, se entrenará con los datos proporcionados y se evaluarán los resultados del mismo hasta que las predicciones se ajusten con los datos históricos. El modelo entrenado será incorporado en una aplicación sencilla que permita el uso por parte del cliente, e irá acompañado de documentación técnica y funcional.

El acuerdo del proyecto no incluye ni la integración de la aplicación con sistemas reales de comercio electrónico o plataformas de reseñas, ni el despliegue de la misma a gran escala.

Listado de requisitos, necesidades y alcance del proyecto

⚠ **Requisitos y necesidades de los interesados**

- **Datos de entrada:** Procesar textos de reseñas en formato de texto que ya están almacenados por la empresa.
- **Procesamiento de Lenguaje Natural (NLP):** Capaz de manejar un lenguaje natural realista, incluyendo variaciones en el estilo y el vocabulario, para poder clasificar un amplio espectro de comentarios.

- **Clasificación automática:** Clasificar de forma automática el sentimiento de cada reseña introducida como positivo o negativo.
- **Interfaz de usuario:** Desarrollo de una pequeña interfaz web utilizando la librería *Streamlit* donde el usuario pueda introducir un comentario y obtener su clasificación.
- **Infraestructura:** Ejecución en un entorno estándar (como un ordenador con sistema operativo *Windows*), sin necesitar una infraestructura compleja.
- **Documentación:** Entrega junto con su correspondiente documentación.

Alcance del proyecto

- Comprensión y análisis del problema y de los requisitos planteados.
- Exploración, tratamiento y preparación de los datos para su uso en el modelo.
- Definición, entrenamiento y evaluación del modelo de clasificación hasta lograr que las predicciones se ajusten correctamente a los datos históricos.
- Incorporación del modelo dentro de la aplicación final para que pueda ser utilizada por el cliente.

Límites del proyecto

- No se realizará la integración de la aplicación con sistemas reales o plataformas de reseñas.
- No se realizará un despliegue de la aplicación a gran escala.

5. Desglose del proyecto en tareas

Realizamos un primer desglose del proyecto en tareas específicas. Es importante contemplar posibles variaciones y mantener la flexibilidad necesaria para garantizar una ejecución óptima del proyecto.

Las tareas más cercanas tienen más detalle, control y certeza en la forma y tiempo de ejecución.

Fase 1

(3-Feb a 3-Mar)

Planificación

- Distribución inicial de tareas
- Creación de repositorio publico
- Planteamiento de cronograma y time-line del proyecto

Análisis de los requisitos

- Definición del proyecto: objetivos, requisitos, arquitectura
- Creación del entregable
- Revisión entregable
- Presentación entregable

Fase 2

(10-Mar a 14-Abr)

Diseño/Codificación

- Recolección de datos a utilizar
- Comprobación de los datos
- Desarrollo del programa
- Documentación de progreso

Fase 3

(21-Abr a 19-May)

Pruebas

- Entrenamiento y testing del modelo
- Documentar resultados
- Revisar y eliminar errores del codigo

Lanzamiento

- Implementación de la interfaz gráfica, user-friendly
- Presentación del proyecto

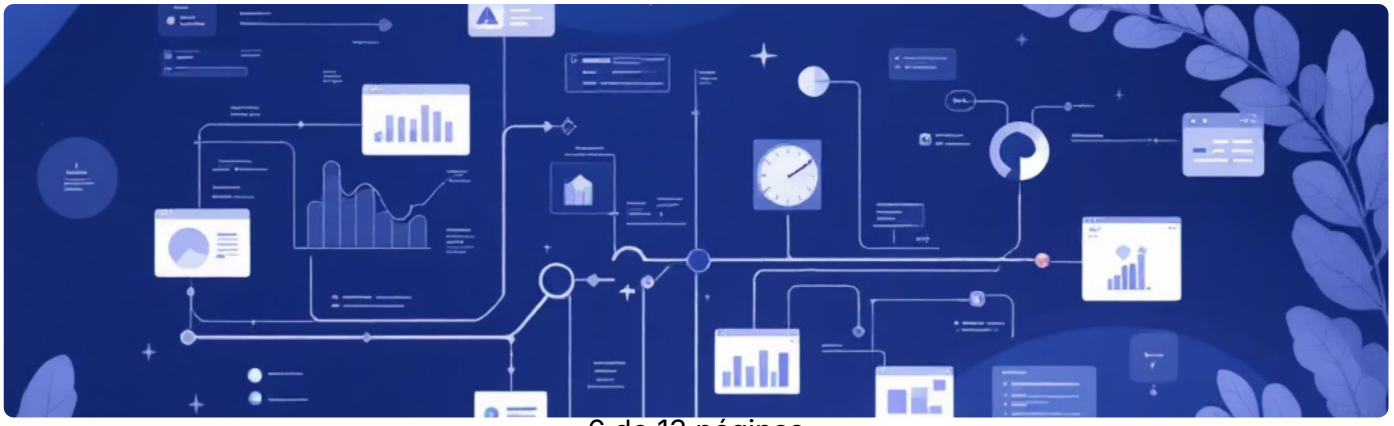

6. Ciclo de vida de los datos

El ciclo de la vida se dividirá en las siguientes fases:

Captura

Dado que contamos con *datasets* sobre análisis de sentimientos relacionados con diversas películas, proporcionados por la Universidad de Stanford y por la Universidad de Cornell, no será necesario recopilar datos desde cero. El proceso consistirá en la extracción de información, ya sea accediendo a los archivos disponibles en el repositorio digital abierto de Meta o importándolos mediante una librería de *Python*. Cada archivo incluye tres conjuntos de datos distintos sobre reseñas de películas, con variaciones de estilo y vocabulario diseñadas para reflejar el lenguaje natural.

Almacenamiento

Contamos con tres *datasets* en formato `.txt` que contienen reseñas de usuarios, clasificadas en positivas y negativas. Dado que se trata de datos no estructurados, es óptimo utilizar bases de datos no relacionales disponibles en la nube, como Word2Vec. Esta elección permite un manejo más eficiente del lenguaje natural y facilita la integración de herramientas de procesamiento de texto sin las limitaciones de un esquema rígido.

Preprocesado

Uniremos los tres *datasets* en uno solo y, a continuación, crearemos una jerarquía para clasificar los atributos del conjunto de datos. Posteriormente, realizaremos una limpieza del dataset, eliminando ruido e inconsistencias, normalizando el texto a minúsculas, eliminando stopwords y aplicando tokenización (división del texto en palabras individuales).

Análisis (Minería de datos)

Crearemos un modelo que explique las características de los datos.

Emplearemos un enfoque de aprendizaje supervisado, que nos permitirá identificar patrones lingüísticos a partir de datos previamente etiquetados. Asimismo, desarrollaremos un clasificador basado en K-Nearest Neighbors (k-NN), que asignará una categoría a cada reseña según su cercanía vectorial con ejemplos ya clasificados, con el objetivo de determinar si el sentimiento es positivo o negativo.

Nuestro propósito será identificar automáticamente el sentimiento y obtener conclusiones fiables frente a grandes volúmenes de reseñas.

Visualización

Representamos los resultados para facilitar la extracción de conocimiento.

Se utilizará una interfaz web llamada Streamlit, diseñada para ser intuitiva y accesible para personal no experto en inteligencia artificial. La interfaz permitirá introducir reseñas en lenguaje natural y obtener de forma inmediata su clasificación como positiva o negativa.

El sistema facilitará tareas básicas, como el filtrado de opiniones irrelevantes y la obtención de detalles bajo demanda sobre grupos específicos de reseñas.

El objetivo es proporcionar una herramienta de apoyo que simplifique la comprensión de grandes volúmenes de datos, permitiendo una toma de decisiones basada en la percepción real del usuario.

Publicación

Documentaremos el *dataset* creado para facilitar su utilización en futuros proyectos. Posteriormente, se ejecutará una preservación en un repositorio digital en la nube para asegurar la disponibilidad, integridad y seguridad de los datos a largo tiempo.

Preservación

El objetivo es garantizar la conservación a largo plazo de los datos y del modelo desarrollado. Para ello, se priorizará el archivo de las reseñas y de las versiones del modelo más relevantes, se aplicará un proceso de estandarización para facilitar su uso por otros departamentos y se emplearán formatos compatibles como JSON o CSV. Además, se gestionarán adecuadamente las licencias y la privacidad, y se acompañarán los archivos con documentación que describa la metodología y los parámetros utilizados.

Archivo

Cuando los datos pierden su relevancia operativa inmediata, se pasan a una fase de archivo para su consulta histórica o cumplimiento legar. Debido a esto se debe establecer cuando se archivaran los datos, donde se almacenaran y durante cuanto tiempo permanecerán archivados.

Eliminación

Cuando se cumpla la etapa de retención, se procederá a la eliminación definitiva del *dataset*. En este proceso se tendrá que eliminar los datos de manera segura, para que estos datos no puedan ser reconstruidos. Esta es una fase crítica para el cumplimiento de la privacidad y la optimización del almacenamiento usado.

7. Planificación del proyecto

Realizaremos toda la planificación del proyecto mediante **GitHub**. Esta plataforma nos permite sincronizar las tareas en *issues* y realizar una planificación del proyecto con diagramas en tiempo real. Además podemos relacionar las *issues* con los *commit* que actualizan el **repositorio**.

Hemos desarrollado un script en *Python*, con ayuda de Gemini, que permite generar de forma automatizada diagramas de PERT y de Gantt a partir de la planificación del proyecto desde la API de GitHub. Está ubicado en el directorio `/tools/generador-diagramas`

El objetivo de esta herramienta es facilitar la visualización de dependencias, tiempos estimados y ruta crítica (en el caso del PERT), así como la distribución temporal de tareas y su seguimiento (en el caso del Gantt). De este modo, tenemos una visión del avance del proyecto.

Diagramas de Gantt

En el siguiente gráfico se muestra el diagrama de Gantt del primer sprint. Al tratarse de un periodo cercano en el tiempo, la planificación es bastante precisa y las estimaciones son más ajustadas.

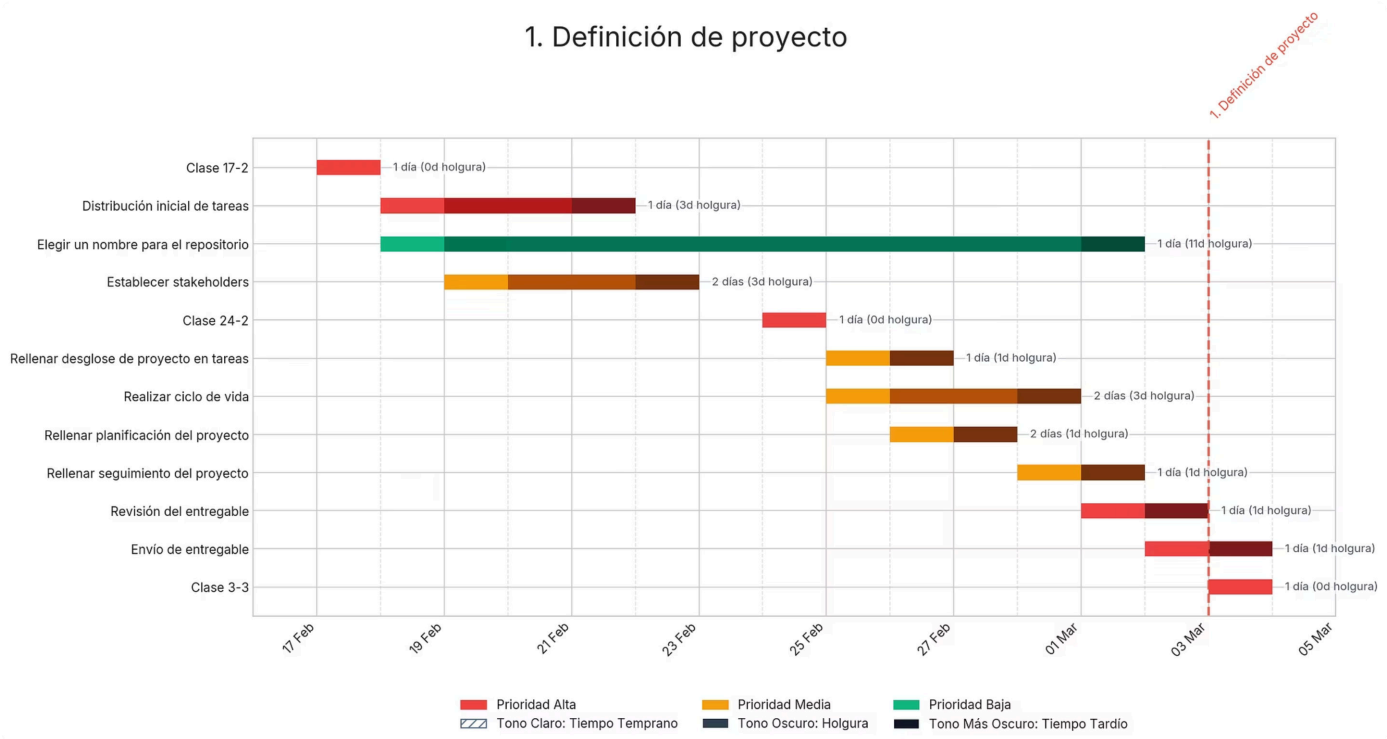

Además, hemos elaborado una primera versión de los diagramas del segundo y tercer sprint. Aunque aún pueden sufrir cambios, nos sirven como guía para visualizar cómo se distribuirán las tareas más adelante y para hacernos una idea del ritmo y la organización del trabajo en las próximas etapas.

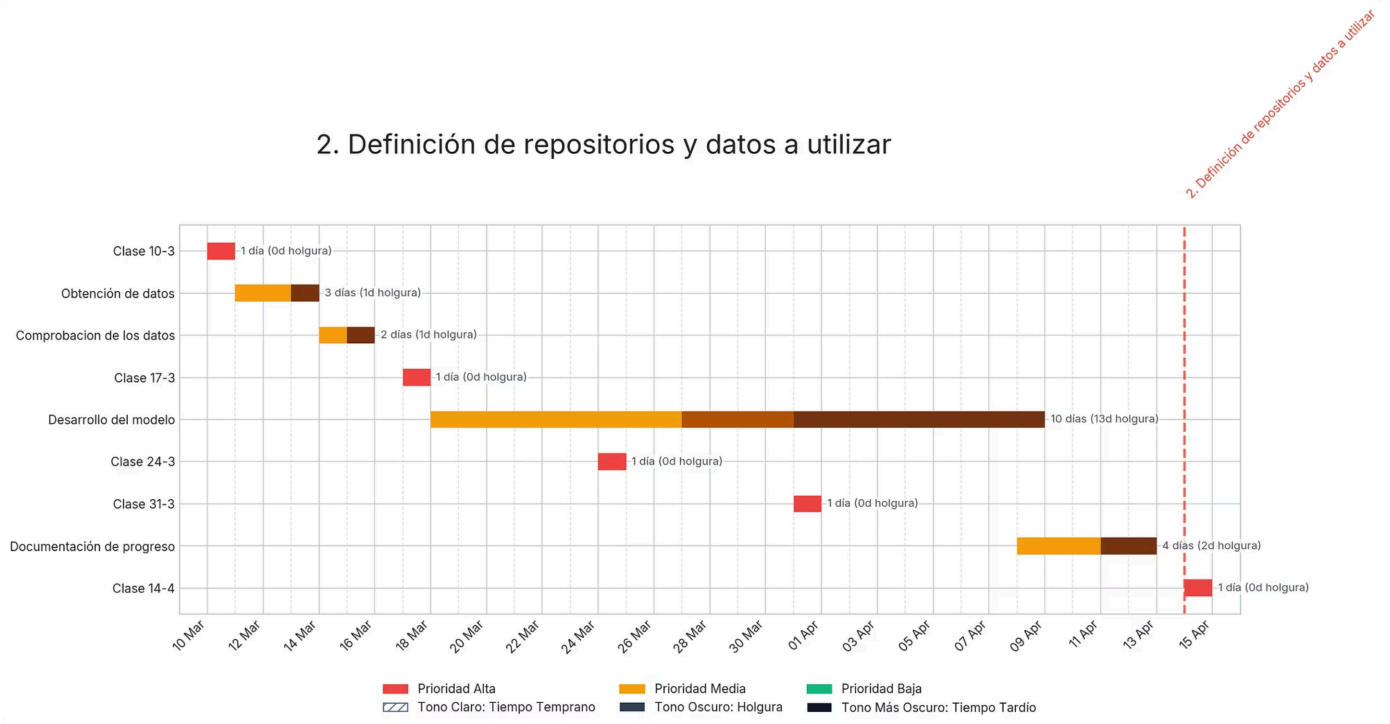

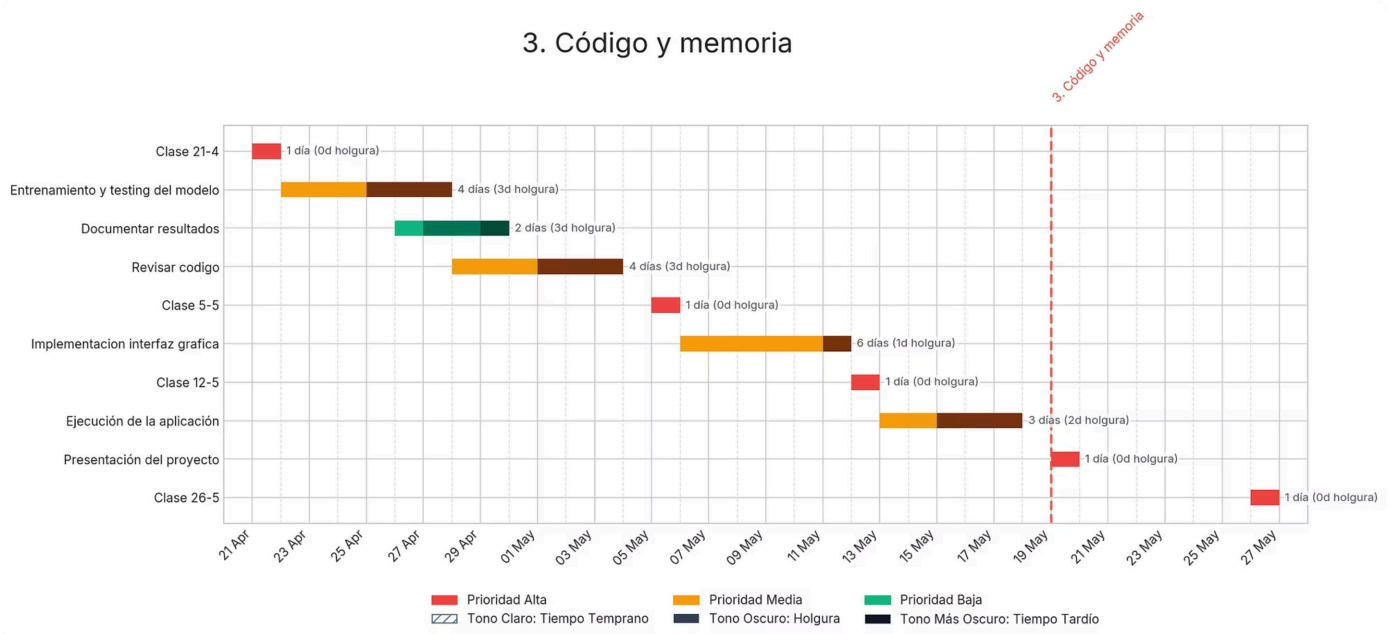

Diagrama PERT

Representamos el diagrama PERT de las tareas planificadas para el primer sprint. En él se muestran los tiempos de inicio y fin tanto de tempranos como tardíos, así como el camino crítico del sprint.

8. Seguimiento del proyecto

Al igual que la planificación, realizaremos el seguimiento del proyecto en **GitHub**. Podremos establecer, actualizar y auditar cada *issue* estableciendo el desarrollador responsable, importancia, fechas límite, etc.

Utilizamos una tabla *Kanban* para visualizar el progreso de las tareas. A continuación vemos un ejemplo:

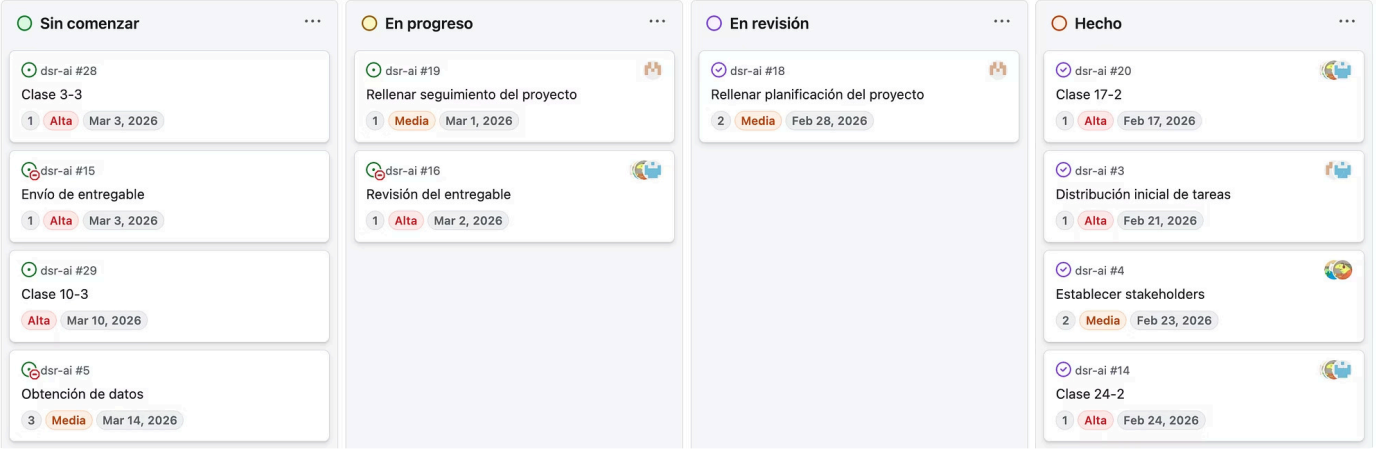

En cada tarea podemos ver las personas que están asignadas, la duración (días), la prioridad y la fecha límite (final tardío).

Si entramos en el *issue* podemos ver toda la información detallada:

Reuniones

Programaremos reuniones periódicas para debatir y consensuar el progreso del trabajo. Estas podrán celebrarse de forma presencial o en línea.

En cada reunión se elaborará un acta que recoja los puntos tratados, las decisiones consensuadas y las tareas asignadas. Todas las actas se subirán al **repositorio** en el directorio `docs/reuniones/`.

Por ejemplo, el acta de la reunión 1 tiene el siguiente formato:

Acta de Reunión 1: Arranque y Entorno de Trabajo

Fecha: 17/02/2026

Asistentes:

- Adrián A. Acosta Villegas
- Sergio Garfella Pérez
- Ainara Sanfélix Ruiz
- Jairo E. Urdaneta Colmenares.

Orden del día:

- Organización e infraestructura del proyecto
- Planificación de tareas
- Sistema de seguimiento del desarrollo

Desarrollo de la reunión

Durante la reunión se debatió sobre la infraestructura y la organización del proyecto, acordándose centralizar toda la planificación mediante la plataforma *GitHub*.

Se optó por emplear los issues del repositorio para asignar tareas, organizar prioridades y establecer fechas de entrega.

Además, se decidió que el progreso se registrará vinculando cada issue con los commits correspondientes en el repositorio público.